

# Evaluación Comparativa entre un Modelo Residual Ligero y ResNet50 para Clasificación Histopatológica de Cáncer Pulmonar

Joel Luis Ibaceta Canchaya  
Universidad Nacional de Ingeniería  
joel.ibaceta.c@uni.pe

Marco Antonio Barrera Ninamango  
Universidad Nacional de Ingeniería  
marco.barrera.n@uni.pe

Jesus Gianpierre Campos Cardenas  
Universidad Nacional de Ingeniería  
j.campos.c@uni.pe

**Abstract**—Este estudio explora el uso de redes neuronales convolucionales residuales para la clasificación de imágenes histopatológicas de cáncer de pulmón, comparando dos enfoques: un modelo ligero personalizado, *ResNetLung*, basado en ResNet-18, y una red profunda preentrenada, ResNet50. Ambos modelos fueron evaluados sobre un subconjunto del dataset LC25000, centrado en adenocarcinoma, carcinoma de células escamosas y tejido sano. *ResNetLung*, entrenado desde cero por 10 épocas, logró una precisión del 96% y un macro F1-score de 0.96, superando a ResNet50, que alcanzó un 88.6% de precisión tras 30 épocas de ajuste fino. Los resultados evidencian que, en dominios visuales específicos como la histopatología, modelos más simples y alineados al problema pueden superar a arquitecturas más complejas, brindando además ventajas en eficiencia computacional y estabilidad. Este trabajo resalta el potencial de soluciones adaptadas al dominio para asistir en el diagnóstico médico automatizado.

## I. INTRODUCCIÓN

El cáncer de pulmón es una de las principales causas de mortalidad a nivel mundial. El diagnóstico temprano mediante análisis histopatológico es esencial para mejorar el pronóstico, pero requiere tiempo, recursos especializados y experiencia médica considerable. La automatización de esta tarea mediante técnicas de inteligencia artificial puede acelerar y estandarizar la detección de patrones patológicos.

En este trabajo se propone un modelo convolucional residual, denominado *ResNetLung*, implementado desde cero con una arquitectura tipo ResNet-18 para clasificar imágenes histológicas de tejido pulmonar. Además, se incluye una prueba comparativa con una red profunda preentrenada ResNet50 [?], permitiendo evaluar el desempeño entre un modelo ligero personalizado y uno de mayor profundidad ampliamente utilizado.

## II. METODOLOGÍA

### III. DATASET

Se utilizó el conjunto de datos LC25000, del cual se seleccionaron únicamente las clases relacionadas al pulmón: adenocarcinoma (*lung\_aca*), tejido sano (*lung\_n*) y carcinoma de células escamosas (*lung\_scc*). Cada clase contiene imágenes histopatológicas teñidas con hematoxilina y eosina (H&E), capturadas con aumentos microscópicos homogéneos.

La Figura ?? muestra una selección de imágenes representativas para cada clase, donde se pueden observar diferencias visuales en la morfología celular y la estructura del tejido.




Fig. 1. Ejemplos de imágenes histopatológicas por clase: adenocarcinoma (arriba), tejido sano (medio), y carcinoma escamoso (abajo).

### A. Arquitectura del Modelo

Se compararon dos enfoques arquitectónicos para la clasificación de imágenes histopatológicas de cáncer de pulmón. El primero, que denominamos *ResNetLung*, corresponde a una red convolucional residual ligera, implementada desde cero con una configuración equivalente a ResNet-18. Esta red está compuesta por una capa convolucional inicial, cuatro bloques residuales organizados en la secuencia [2,2,2,2], una capa de *pooling* global y una capa densa final. El diseño prioriza la eficiencia computacional sin sacrificar capacidad expresiva.




Fig. 2. Arquitectura de la red *ResNetLung*, con bloques residuales organizados en cuatro etapas y salida para tres clases.

El segundo enfoque utiliza una arquitectura ResNet50 [?], considerablemente más profunda, preentrenada sobre el conjunto ImageNet y adaptada a la tarea mediante aprendizaje transferido. Se removió la cabeza clasificadora original y se añadió una nueva capa densa con tres salidas y activación softmax. Las capas convolucionales del modelo base se mantuvieron congeladas durante el entrenamiento.




Fig. 3. Arquitectura interna de ResNet50, compuesta por una capa inicial convolucional y cinco etapas residuales con bloques de convolución (Conv Block) y de identidad (ID Block), seguidas de un clasificador denso.

### B. Justificación de ResNet-18

La elección de ResNet-18 se fundamenta en su equilibrio entre profundidad y eficiencia computacional. Estudios previos demuestran su eficacia en tareas médicas similares. En [?] se usó ResNet-18 para clasificación citológica respiratoria con buenos resultados. En [?] se utilizó exitosamente para clasificación de lesiones prostáticas.

## IV. ENTRENAMIENTO

Se entrenaron por separado dos modelos para la clasificación multiclase de imágenes histopatológicas: *ResNetLung*, diseñado desde cero, y *ResNet50*, un modelo profundo preentrenado. A continuación, se detalla el proceso de entrenamiento de cada uno.

1) *Entrenamiento de ResNetLung*: El modelo *ResNetLung* fue entrenado desde cero durante 10 épocas, utilizando el optimizador Adam con una tasa de aprendizaje inicial de 0.001 y la función de pérdida *CrossEntropyLoss*. Todos los pesos de la red fueron inicializados aleatoriamente y optimizados durante el entrenamiento. El proceso se realizó en

un sistema macOS con soporte para MPS (Metal Performance Shaders).

La Tabla ?? muestra la evolución del desempeño del modelo a lo largo de las épocas. Se observa una disminución progresiva de la pérdida, desde 0.3668 en la primera época hasta 0.1136 en la última, acompañada de un incremento sostenido en la exactitud, alcanzando un valor final del 95.61%.

TABLE I  
EVOLUCIÓN DEL DESEMPEÑO DE *ResNetLung* POR ÉPOCA

Época	Loss	Accuracy
1	0.3668	85.62%
2	0.2530	89.48%
3	0.1953	91.87%
4	0.1860	92.57%
5	0.1841	92.73%
6	0.1511	94.03%
7	0.1383	94.25%
8	0.1284	94.93%
9	0.1269	94.89%
10	<b>0.1136</b>	<b>95.61%</b>

El reporte de clasificación fue el siguiente:

TABLE II  
REPORTE DE CLASIFICACIÓN DEL MODELO *ResNetLung* SOBRE EL CONJUNTO DE PRUEBA

Clase	Precisión	Recall	F1-score	Soporte
lung_aca	1.00	0.87	0.93	958
lung_n	1.00	1.00	1.00	1016
lung_scc	0.89	1.00	0.94	1026
<b>Accuracy</b>	0.96 (3000 imágenes)			
<b>Macro avg</b>	0.96	0.96	0.96	3000
<b>Weighted avg</b>	0.96	0.96	0.96	3000

La Figura ?? presenta la matriz de confusión obtenida tras evaluar el modelo sobre el conjunto de prueba. El clasificador muestra un rendimiento robusto en las tres clases analizadas: adenocarcinoma pulmonar (lung\_aca), tejido pulmonar sano (lung\_n) y carcinoma escamoso pulmonar (lung\_scc).




Fig. 4. Matriz de confusión del modelo *ResNetLung* sobre el conjunto de prueba.

2) *Entrenamiento de ResNet50*: La red *ResNet50* fue utilizada como base preentrenada sobre el conjunto ImageNet. Su arquitectura original fue modificada eliminando la capa densa final y añadiendo una nueva capa con tres salidas y activación softmax, adaptada a las clases del problema. Las capas convolucionales del modelo fueron congeladas, entrenándose únicamente la cabeza clasificadora.

El modelo fue entrenado durante 30 épocas bajo los mismos parámetros de optimización: el optimizador Adam con una tasa de aprendizaje de 0.001 y la función de pérdida *CrossEntropyLoss*. Este mayor número de épocas buscó compensar la menor cantidad de capas entrenables. El objetivo fue evaluar el rendimiento de un modelo ligero y personalizado frente a uno más profundo y preentrenado para este tipo de tarea.

La matriz de confusión obtenida se muestra en la Figura ??.

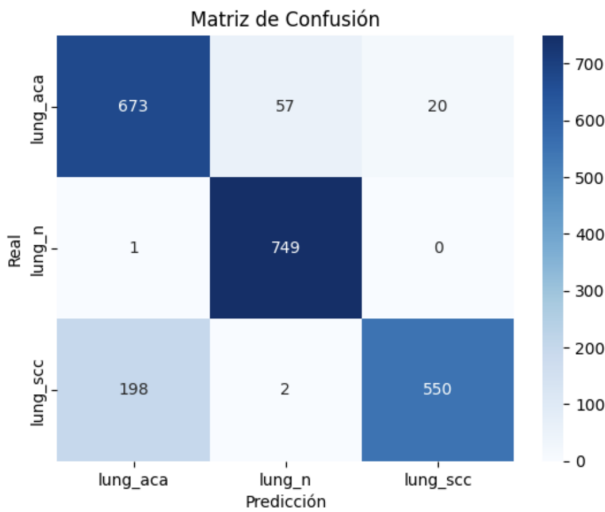


Fig. 5. Matriz de confusión del modelo *ResNet50*.

El reporte de clasificación fue el siguiente:

TABLE III  
REPORTE DE CLASIFICACIÓN DEL MODELO *ResNet50* SOBRE EL CONJUNTO DE PRUEBA

Clase	Precisión	Recall	F1-score	Soporte
lung_aca	0.77	0.90	0.83	750
lung_n	0.93	1.00	0.96	750
lung_scc	0.96	0.73	0.83	750
<b>Accuracy</b>	0.88 (2250 imágenes)			
<b>Macro avg</b>	0.89	0.88	0.87	2250
<b>Weighted avg</b>	0.89	0.88	0.87	2250

## V. RESULTADOS Y ANÁLISIS

A pesar de que *ResNet50* es una arquitectura profunda ampliamente validada en tareas generales de clasificación de imágenes, los resultados obtenidos en este trabajo muestran que no necesariamente supera a modelos más ligeros cuando se trata de dominios visuales específicos como la histopatología.

El modelo *ResNetLung* (basado en *ResNet-18*), entrenado desde cero, logró una precisión del 96

En imágenes histopatológicas, especialmente aquellas teñidas con hematoxilina y eosina (HE), las estructuras relevantes —como núcleos celulares, espacios alveolares y agrupaciones anómalas— suelen presentarse como configuraciones visuales simples: formas circulares, texturas lineales, repeticiones de puntos o agrupamientos densos. Estos patrones son visualmente distintivos, pero no excesivamente complejos, por lo que no requieren modelos con una gran profundidad ni una jerarquía de abstracciones tan pronunciada como en tareas como clasificación de escenas, objetos naturales o rostros.

En este contexto, una red liviana pero especializada puede aprender eficientemente los patrones morfológicos clave sin sobreajustarse, especialmente si se entrena desde cero sobre el dominio específico. Esto contrasta con *ResNet50*, cuyo preentrenamiento sobre ImageNet incorpora una fuerte inductiva visual generalista, no necesariamente alineada con las características de tejido tumoral.

Además, *ResNetLung* convergió en solo 10 épocas, mostrando un entrenamiento estable, sin signos de sobreajuste y con gran generalización. En cambio, *ResNet50* requirió 30 épocas para aproximarse a una precisión menor, y presentó más fluctuaciones en su curva de validación, lo que indica menor estabilidad en este dominio.

Por lo que concluimos que, para datasets histológicos con estructuras visuales poco intrincadas pero altamente discriminativas, la clave no está en la complejidad del modelo, sino en su adaptación al dominio. Arquitecturas livianas bien diseñadas no solo son más eficientes computacionalmente, sino que pueden superar a modelos pesados si se alinean con la naturaleza de los datos.

TABLE IV  
COMPARACIÓN DE DESEMPEÑO ENTRE *RESNETLUNG* Y *RESNET50*

Métrica	<i>ResNetLung</i> ( <i>ResNet-18</i> )	<i>ResNet50</i>
Épocas de entrenamiento	10	30
Precisión general	<b>96.0%</b>	88.6%
F1-score (macro promedio)	<b>0.96</b>	0.87
Tamaño del modelo	Bajo	Alto
Convergencia rápida	Sí	No
Tendencia al sobreajuste	Baja	Media
Alineación con el dominio	Alta	Moderada

## VI. CONCLUSIONES

Los resultados obtenidos en este estudio demuestran que una arquitectura residual ligera como *ResNetLung* (basada en *ResNet-18*) puede alcanzar un desempeño sobresaliente en la clasificación de imágenes histopatológicas pulmonares, logrando una precisión del 96% y un macro F1-score de 0.96 tras solo 10 épocas de entrenamiento.

En comparación, una versión más profunda como *ResNet-50*, entrenada durante 30 épocas, obtuvo un rendimiento inferior (88.6% de precisión), evidenciando un menor ajuste al problema pese a su mayor capacidad. Esto sugiere que, en datasets de imágenes histológicas donde los patrones tienden a ser estructuras simples (como círculos, líneas y texturas regulares propias del tejido tisular), modelos más pequeños

y eficientes pueden ser más adecuados, evitando sobreajuste y reduciendo la carga computacional.

La matriz de confusión mostró que el modelo ligero clasifica con alta precisión el tejido sano y el carcinoma escamoso, mientras que las confusiones principales se dieron entre adenocarcinoma y carcinoma escamoso, posiblemente debido a la similitud visual entre estas clases. Este hallazgo abre la posibilidad de mejorar el rendimiento mediante técnicas complementarias como el aumento de datos, mecanismos de atención o entrenamiento focalizado.

Finalmente, gracias a su bajo costo computacional, rápida convergencia y facilidad de integración, *ResNetLung* representa una solución prometedora para aplicaciones clínicas asistidas por IA, siendo escalable y adaptable a otros contextos médicos con necesidades similares.

## REFERENCES

- [1] W. Wang et al., "PI-RADS 3 lesion classification based on ResNet18 in T2-weighted images," *Frontiers in Oncology*, vol. 13, 2024.
- [2] Y. Xu et al., "Deep learning model based on an improved ResNet18 for on-site diagnosis of respiratory cytological samples," *BMC Cancer*, vol. 24, no. 1, 2024.
- [3] K. He, X. Zhang, S. Ren, and J. Sun, "Deep Residual Learning for Image Recognition," in *Proc. of CVPR*, 2016.
- [4] Kaggle, "Lung and Colon Cancer Histopathological Images," [Online]. Available: <https://www.kaggle.com/datasets/andrewmvd/lung-and-colon-cancer-histopathological-images>
- [5] A. Paszke et al., "PyTorch: An Imperative Style, High-Performance Deep Learning Library," in *NeurIPS*, 2019.
- [6] "LungCancer-ResNetClassifier," GitHub repository, 2025. [Online]. Available: <https://github.com/joelibaceta/LungCancer-ResNetClassifier>
- [7] K. He, X. Zhang, S. Ren, and J. Sun, "Deep Residual Learning for Image Recognition," in *Proc. of CVPR*, 2016.